Задание 1. Справочник сайтов организаций

Что именно собираем

Я бы начал с определения связи, которую обещаем пользователю API. Основной сайт - это сайт, через который организация представляет себя или свой основной бренд и оказывает услуги. Карточка на маркетплейсе, страница работодателя, профиль в социальной сети и упоминание в новости этой связью не являются. Если у компании несколько равноправных брендов и основной не определяется, лучше сохранить кандидатов внутри справочника, а единственный основной домен не выдавать.

Связь не обязана быть один к одному. Несколько юридических лиц могут работать через сайт группы, а одно юридическое лицо - через несколько доменов. Нельзя выбирать сайт материнской компании только по аффилированности. Нужно подтвердить роль конкретного лица: оператор сервиса, продавец, правообладатель или организация, которую сайт представляет. Для франшизы различаем владельца бренда и местного франчайзи. При поиске по одному ИНН не обещаем сайт отдельного филиала; для этого потребуется КПП и другой контракт ответа.

Начальный охват - действующие российские юридические лица. ИП добавляем отдельным сегментом: сайтов и публичных идентифицирующих сведений у них меньше. null означает «сайт не установлен с достаточными основаниями». Он не означает доказанное отсутствие сайта. Ошибки источников и временная недоступность учитываются отдельно.

Откуда брать кандидатов

Источник	Польза	Ограничение
Поиск по ИНН, затем названию и региону	Быстрый старт, помогает найти реквизиты и документы	Выдача часто занята каталогами; результат зависит от индекса
Публичные бизнес-каталоги и отраслевые реестры	Название, адрес, телефон, иногда ссылка на сайт	Данные устаревают; каталоги могут копировать один источник
Обход известных сайтов и поиск ИНН в документах	Сильная связь «сайт - организация», один сайт может дать несколько связей	Нужно понимать, кому относится ИНН; полный обход сети дорог
Корпоративная почта, пользовательские исправления	Дешёвые кандидаты и сигналы обновления	Домен почты может отличаться от сайта; исправления требуют проверки

ЕГРЮЛ/ЕГРИП задают идентичность организации, но не решают задачу поиска сайта. В продукте я использовал бы уже имеющиеся у DaData название, адрес, статус, ОГРН и историю изменений. Готовое поле сайта из DaData не используется ни для поиска, ни как эталон собственной оценки: это создало бы круговую проверку.

Выбор - сочетание источников. Сначала обрабатываем востребованные ИНН и существующие кандидаты из разрешённых источников. Дополняем их поиском и ограниченным чтением сайтов. Найденные на одном сайте реквизиты остальных организаций группы можно отправлять на отдельную проверку. Такой подход даёт полезный результат раньше, чем сплошной обход всех организаций.

Как подтверждать связь

Разделяю получение кандидатов и принятие решения. Для кандидатов сохраняю источник, URL и время получения. На самом сайте ищу контакты, реквизиты, оферту, политику обработки данных и текстовые PDF. Нормализую домены, учитываю международные имена, поддомены, конструкторы сайтов и перенаправления. После перехода на другой домен принадлежность проверяется заново.

Сильное свидетельство - точный ИНН или ОГРН в документе самого сайта, где ясно указана роль организации. Но одного совпадения цифр недостаточно: это могут быть реквизиты банка получателя, клиента, подрядчика или участника судебного дела. Если идентификатор не опубликован, в большом справочнике допускаю несколько независимых совпадений: название, адрес, телефон и подтверждённая внешняя ссылка. Этот путь требует отдельной калибровки и более осторожного порога. В практическом прототипе выбран более строгий режим: нужен точный ИНН на прочитанной странице. При нескольких собственных доменах отдельно проверяется их отношение: головной сайт и продукт либо равноправные бренды. Выбор головного сайта требует свидетельств каждого домена; широта услуг сама по себе не устанавливает основной бренд. При неясной иерархии ответ не выдаётся.

Обычные правила проверяют идентификаторы, домены, дубликаты и технические ограничения. LLM извлекает смысл связи и противоречия из коротких фрагментов. Она возвращает структурированное решение с ID свидетельства. В прототипе программа сама прикрепляет дословный фрагмент выбранной страницы и проверяет его ИНН и домен. Уверенность, которую модель сама написала числом, не считаю вероятностью правильного ответа.

Для производства порог принятия выбирается по размеченным данным и цене ошибки. Стартовая цель - высокая точность выдаваемых связей; конкретное значение согласуем с продуктом. Условные 99% - целевой уровень, а не обещание прототипа. Неоднозначные записи отправляются на ручную проверку либо остаются без основного домена. Отрицательные результаты поиска тоже сохраняются, чтобы не оплачивать один и тот же поиск на каждом запросе.

Что хранить и как отдавать

Минимальная запись: ИНН, кандидат-домен, тип связи, признак основного сайта, статус решения, свидетельства, версия правил и модели, даты первого обнаружения и последней проверки, следующая дата проверки. Для каждого свидетельства нужны URL, фрагмент, хеш содержимого и время получения; для поискового или удалённого кеша - отметка о неизвестной дате исходной страницы. История сохраняет предыдущие решения и причину изменения.

Внешний API читает опубликованную версию справочника. Поиск и LLM работают асинхронно в очереди обновлений, чтобы время ответа API и его доступность не зависели от поискового сервиса. Повторные задачи по одному ИНН объединяются. Несколько запросов на один домен используют общий результат чтения. На первом этапе достаточно таблиц организаций, связей и свидетельств, очереди задач и небольшого интерфейса разметки.

Как оценить качество

Создаю выборку с заранее заданным распределением по размеру, региону и отрасли; отдельно включаю ИП, одноимённые компании, группы, франшизы, ликвидированные организации и случаи без найденного сайта. Эталон устанавливается ручной проверкой первичных страниц. Спорные случаи проверяет второй разметчик; разногласия разрешаются по опубликованным правилам. Эталон имеет дату: сайт и юридическое лицо могут измениться.

Нужно измерять качество получения кандидатов отдельно от качества решения. Если правильного сайта нет среди кандидатов, улучшение промпта не исправит проблему поиска. Данные для разработки, настройки порога и окончательной оценки разделяются; связанных компаний одной группы нельзя разносить между частями случайно. Дополнительно полезен тест на более поздних данных.

Какие показатели смотреть

Точность выдачи = правильные связи / все выданные связи. Полнота среди компаний с подтверждённым сайтом = найденные правильные связи / все такие компании в эталоне. Покрытие = ИНН с опубликованным доменом / все ИНН заданного охвата. Эти показатели отвечают на разные вопросы: высокую точность можно получить ценой большого числа отказов.

Также считаю ложные ответы для случаев без подтверждённого сайта, долю технических ошибок, долю устаревших связей, задержку обнаружения изменений, стоимость обработки и ручной проверки, медиану и p95 времени. Смотрю показатели по сегментам и причины ошибок. Для небольших выборок публикую число наблюдений и интервалы неопределённости, а не только проценты. Отсутствие сайта нельзя достоверно установить обычным поиском, поэтому такие эталонные метки формулирую как «не подтверждён после установленной процедуры проверки».

Сравниваю три варианта на одних и тех же исходных данных: первый результат поиска, правила с точным ИНН и правила плюс LLM. Это покажет, что даёт семантический анализ. Для разных источников сравниваю долю правильных кандидатов, итоговую точность, полноту, расходы и время. Полезный результат модели должен оправдывать стоимость её эксплуатации.

Как поддерживать актуальность

Частоту проверки назначаю по востребованности, возрасту свидетельства и риску ошибки. Начальная гипотеза: востребованные записи проверять ежемесячно, остальные подтверждённые - ежеквартально; сомнительные - раньше. Эти интервалы пересматриваются по наблюдаемой скорости изменений. Смена названия, статуса, контактов или реорганизация запускает внеочередную проверку. Приоритеты ограничены общим дневным бюджетом.

Сначала делаем дешёвую проверку DNS, HTTP и перенаправлений. Если важная страница не изменилась, используем её хеш или HTTP-валидаторы. Доступность сайта не подтверждает принадлежность: периодически всё равно перечитываем реквизиты и проверяем роль. Новый владелец домена, парковка, исчезнувшие реквизиты или несовместимый ИНН отправляют связь на перепроверку.

Один таймаут не удаляет хороший ответ. Запись получает технический статус и ограниченные повторы с увеличением интервала. При подтверждённом противоречии домен снимается с выдачи до проверки. Неподтверждённые результаты поиска пересматриваются, например через месяц, а затем реже; отсутствие результата не кешируется навсегда. Пользовательские сообщения об ошибке имеют высокий приоритет, но не меняют справочник без проверки.

Изменения публикуются небольшими версиями с возможностью отката. На каждой версии контролирую точность на постоянной контрольной выборке, необычный рост отказов и резкую смену доменов. Смена модели или поискового провайдера сначала проходит повторную оценку на сохранённых свидетельствах и затем на свежей выдаче.

Ограничения и вопросы до запуска

Главные ограничения - неполная индексация, сайты без реквизитов, закрытые страницы, сканы, динамический контент, копирование чужих документов и устаревшие сведения. LLM может ошибиться в роли организации даже при настоящей цитате. Несколько внешних каталогов не обязательно независимы. Бесплатный поисковый лимит подходит для прототипа, но не обеспечивает массовый сбор и SLA; собственный метапоиск тоже зависит от доступности внешних движков.

До запуска согласуем охват, определение основного сайта, допустимость сайтов группы и отдельных брендов, цену ложной связи, правила истечения срока проверки и обработку ликвидированных организаций. Отдельно проверим условия использования источников, доступные способы выгрузки и хранения свидетельств. Обходим сайты с ограничением нагрузки и учётом robots.txt; публичные персональные данные ИП собираем только в необходимом объёме. Бесплатный web search не означает нулевую стоимость инфраструктуры и поддержки справочника.

Задание 2. Поиск сайта по ИНН

Репозиторий: GitHub. Профиль GitHub: Ev0lv3nta.

Контракт и инструменты

Вход — {"inn":"7721581040"}, выход — {"domain":"dadata.ru"} или {"domain":null}. ИНН передаётся строкой; формат и контрольная сумма проверяются до сети. Поддержаны ИНН юрлиц и ИП; качество на ИП отдельно не оценивалось. Команда принимает JSON из stdin либо --inn. В stdout только ответ. Неверный вход имеет код завершения 2, сбой инструментов или таймаут — код 3 и причину в stderr; обоснованный отказ — код 0.

Поиск работает через CRW REST API с собственным SearXNG. Чтение использует HTTPX, BeautifulSoup и pypdf; при неудаче — CRW с Lightpanda и Chromium, запущенным Playwright. Для юридических сведений важен полный HTML с футером и ссылками, поэтому удалённое чтение не ограничено основным текстом статьи. Публичные данные из JSON-LD и JSON состояния страницы тоже извлекаются. При HTTP-разборе JavaScript не исполняется; удалённые браузеры могут выполнить его для загрузки страницы. Название и регион запрашиваются в публичном сервисе ЕГРЮЛ/ЕГРИП ФНС. Его недоступность не останавливает поиск. Частный сервер для запуска не нужен: конфигурация и скрипт запуска включены в репозиторий.

SearXNG обращается к публичным поисковым движкам, платных поисковых API в итоговых прогонах нет. Дополнительный шлюз Tavily/Brave выключен; он проверен моками, живых ключей нет. Обновление парсера Yahoo помогло восстановить поиск по названию после исчерпания анонимной квоты Exa и ограничений других движков. Версии CRW, SearXNG и Playwright зафиксированы в документации стека и отчёте проверки.

LLM — openai/gpt-6-luna через OpenRouter, reasoning high, строгая JSON Schema. Модель выбирает операции и определяет смысл связи; Pydantic и обычный Python проверяют форму ответа, источник и домен. Агентный фреймворк для такого цикла не нужен. Зависимости Python закреплены в uv.lock, Playwright — в package-lock.json.

LLM платная: тариф на момент запуска — $0.10/M входных и $0.50/M выходных токенов. Перед запросами проверяется цена из каталога. Бюджет по умолчанию — $0.25; журнал с блокировкой сначала резервирует верхнюю оценку, затем учитывает фактическую стоимость. Платный web search и автоматическая замена модели выключены. Бесплатный поиск не даёт промышленного SLA.

Как проходит поиск

1. ФНС устанавливает субъект по точному ИНН. Первый запрос строится из краткого юридического названия (при его отсутствии — полного), региона и слов «официальный сайт». Это сохраняет юридическую форму и не требует отдельного вызова LLM. При отсутствии идентификации используется ИНН в кавычках. Дальнейшие запросы выбирает модель.

2. Поиск даёт кандидатов и ссылки. Домены нормализуются через Public Suffix List с учётом IDN и частных зон. Каталоги служат для идентификации и новых ссылок, но не становятся ответом. Модель выбирает страницы контактов, реквизитов, оферт и PDF по смыслу подписей ссылок.

3. LLM получает ограниченный текст и определяет роль: оператор сайта, стороннее упоминание или неясная связь. ИНН банка, клиента, издателя отдельной книги или руководителя другого юрлица не подтверждает владение сайтом. Веб-контент передаётся как недоверенные данные.

4. Для собственного сайта модель выбирает ID прочитанного источника. Python прикрепляет дословный фрагмент с ИНН и проверяет границы числа, источник этого кандидата и совпадение домена. Сниппет не подходит. Неподтверждённый источник или недословная сравнительная цитата возвращаются модели на исправление один раз; действительная неясность связи остаётся основанием для null.

5. Модель задаёт следующий запрос или до трёх URL для чтения. Ей передаются история, ошибки, найденные доказательства и остаток бюджета. JSON Schema и код ограничивают URL уже наблюдавшимися ссылками. Домен выдаётся только при действии finish и принятом свидетельстве. В логике выбора нет словарей юридических страниц, регулярных выражений и подстановок по известным ИНН.

6. Предварительно выбранный основной домен проходит дополнительную проверку, даже если найден только один кандидат. Действующий подтверждённый алиас одного бренда допустим. Разные собственные бренды требуют сравнения: корпоративный сайт и отдельный продукт можно различить с цитатами обоих сайтов. Одна широта каталога не доказывает основной бренд. Неясность даёт null.

Пределы и запуск

Один запуск ограничен девятью шагами модели, четырьмя поисками, шестью активными кандидатами, двенадцатью URL и пятью минутами. Одновременно читаются три страницы. Ограничены размер загрузки, перенаправления, страницы PDF и контекст. Адрес проверяется на частные и служебные сети при каждом HTTP-переходе; запрет robots.txt не обходится удалённым чтением. Для многопользовательского сервиса дополнительно нужна сетевая изоляция браузеров.

Кеш поиска и страниц живёт сутки; --no-cache его отключает. --trace сохраняет запросы, URL, свидетельства, решения, настройки, время и расходы. Время получения не равно дате исходной страницы или её обновления. Полные трассы не публикуются; компактные результаты и принятые фрагменты входят в репозиторий. Технические сбои сохраняются отдельно от отрицательного результата.

Нужны Python 3.11+, uv, ключ OpenRouter и CRW. Запуск своего стека описан в stack/README.md. Клиент: uv sync --frozen, затем с экспортированным ключом uv run inn-site --inn 7721581040. Для банковских сайтов создаётся отдельный CA bundle из сертификатов Госуслуг: uv run python stack/certificates.py. Проверка TLS остаётся включённой, системное хранилище не меняется.

Офлайн-проверки: uv run pytest (90 тестов) и uv run ruff check .. Скрипты evaluate.py и evaluate_llm.py повторяют реальные проверки и расходуют LLM-бюджет. Эталоны и первичные URL из tests/cases.json не передаются алгоритму.

Результаты и ограничения

Последние живые результаты по каждому ИНН: 16/16 подтверждённых основных сайтов, 0 ложных доменов. Пропусков на положительных эталонах: 0; технических сбоев: 0. После полного контроля повторно проверены четыре пропуска. Это объединение последних ответов, а не один безошибочный запуск.

Проверка	Результат
Подтверждённые основные сайты	16/16; ложных доменов 0
Несколько собственных брендов	null, ambiguous
Неверный вход	null, код завершения 2

Текущая LLM дополнительно подтвердила остальные 13 сайтов на сохранённых свидетельствах, без нового поиска. Это известные входы после разработки, не слепой контроль и не оценка качества на всём ЕГРЮЛ. Предыдущие результаты, включая неудачные, сохранены в репозитории.

На 17 синтетических фрагментах LLM с проверкой свидетельства дала 17 правильных ответов и 0 ложных доменов. Простая проверка точного ИНН на тех же текстах: 4 правильных ответов и 13 ложных доменов. Это показывает пользу анализа роли организации на выбранных сложных примерах. Тексты и ответы сохранены в репозитории.

Наборы маленькие и целенаправленно подобраны. Ошибки инструментов не засчитываются как правильный отказ; неверный ИНН не изображает организацию без сайта. Эталон нескольких брендов был исправлен после аудита первичных страниц, исходный неудачный результат сохранён. Все этапы описаны в reports/validation.md, принятые свидетельства — в reports/decisions.json.

Строгий критерий ИНН снижает полноту: сайт может существовать без опубликованных реквизитов. Не реализованы OCR, массовый сбор, обновление справочника и очередь ручной проверки — они описаны в первой части. Возможны ошибки модели в роли организации и ограничения индекса или доступа. Следующий шаг — независимая разметка новых организаций, отдельные сегменты ИП и групп, калибровка порога и оценка расходов обновления.

Codex использован для реализации, тестов и документа. Выбор инструментов подтверждён реальными прогонами; качество поискового индекса и качество анализа оценивались отдельно.

Источники: CRW, SearXNG, Lightpanda, Playwright, ФНС. Первичный источник примера — оферта DaData.