Задание 1. Справочник сайтов организаций

Что считать сайтом организации

Я бы сначала договорился о том, что именно возвращает API. Для этого решения основной сайт представляет организацию или её основной бренд. Карточки в каталогах, страницы на маркетплейсах и профили в соцсетях в ответ не попадают. Если у компании несколько равноправных брендов, нельзя произвольно выбрать один. Кандидатов стоит сохранить, а основной домен оставить пустым.

У одного сайта могут быть несколько юридических лиц, у одного юридического лица могут быть несколько сайтов. Поэтому в базе нужна связь «организация и домен» с пояснением роли: продавец, оператор сервиса, владелец бренда. Само по себе вхождение в группу компаний ничего не доказывает. Например, сайт франшизы ещё не является сайтом каждого франчайзи. Для поиска отдельного филиала одного ИНН тоже недостаточно: понадобится как минимум КПП.

Я бы начал с действующих юридических лиц, а ИП оценивал отдельно. У них чаще нет сайта или публичных реквизитов, поэтому общая метрика скроет разницу в качестве. Ответ null означает, что сайт не удалось подтвердить. Он не доказывает, что сайта нет. Сбой поиска нужно учитывать отдельно.

Где искать

Самый быстрый способ начать: поиск по ИНН, названию и региону. ИНН хорошо находит документы с реквизитами, но выдачу часто занимают бизнес-каталоги. Название помогает выйти на сам сайт, хотя добавляет риск перепутать одноимённые компании. Поэтому нужны оба способа.

Каталоги и отраслевые реестры полезны как источник ссылок, адресов и телефонов. Доверять им без проверки я бы не стал: сведения устаревают, а несколько каталогов могут копировать одну ошибку. Домен корпоративной почты тоже даёт кандидата, но не подтверждает наличие сайта.

Можно идти в обратную сторону: обходить уже известные сайты и извлекать организации из оферт и реквизитов. Это особенно полезно для групп компаний. Полный обход интернета для первого запуска слишком дорог, а чтение найденных сайтов дополняет обычный поиск. Исправления от пользователей также стоит принимать, но проверять по тем же правилам.

Для справочника я бы объединил эти источники. Сначала обработал востребованные ИНН и ссылки, которые уже есть в доступных данных, затем расширял охват. Это позволит раньше проверить пользу сервиса и стоимость одной подтверждённой связи.

ЕГРЮЛ и ЕГРИП нужны, чтобы установить, кого мы ищем. В DaData уже есть название, адрес, статус и история организации. Готовое поле сайта из DaData я бы не использовал: проверять новый справочник по тем же данным, из которых он собран, бессмысленно.

Как проверить найденный сайт

На сайте я бы искал контакты, реквизиты, оферту, политику обработки данных и PDF-документы. Для каждого вывода сохранял бы страницу, дату чтения и фрагмент текста. После перехода на другой домен проверку принадлежности нужно провести заново. При обработке адресов следует учитывать кириллицу, поддомены и сайты на общих платформах.

Точный ИНН или ОГРН в документе самого сайта даёт сильное основание для связи. Но цифры могут относиться к банку получателя, клиенту или подрядчику. Здесь полезна LLM: она читает контекст и определяет роль организации. Обычный код проверяет идентификатор, источник цитаты и домен. Число «уверенность 0.99», написанное моделью, само по себе не считается оценкой точности.

В практической части я выбрал строгий вариант: без точного ИНН на прочитанной странице ответ не выдаётся. Для большого справочника можно добавить подтверждение по названию, адресу, телефону и независимой внешней ссылке. Но этот способ сначала нужно проверить отдельно: он увеличит охват и одновременно риск ложных связей.

При нескольких собственных сайтах остаётся второй вопрос: какой из них основной? Корпоративный сайт и сайт отдельного продукта иногда удаётся различить по описанию на обеих страницах. Широкий каталог товаров ещё не доказывает, что бренд главный. Если иерархия неясна, я бы возвращал null или отправлял запись на ручную проверку.

Как хранить и отдавать результат

Для связи нужны ИНН, домен, роль организации, признак основного сайта, статус проверки и подтверждающие материалы. У каждого материала сохраняются URL, фрагмент текста, хеш и время получения. У решения сохраняются версия модели и правил, дата последней проверки и история изменений. Дата чтения страницы не равна дате её публикации, особенно если источник взят из кеша.

API должен читать готовый справочник. Поиск и LLM работают в фоновой очереди, иначе доступность поисковика будет влиять на каждый запрос к DaData. Повторные задачи по одному ИНН объединяются, а прочитанную страницу можно использовать для нескольких организаций. На первом этапе достаточно базы, очереди и простого интерфейса для разбора спорных записей.

Как измерять качество

Для проверки нужна размеченная выборка с разными регионами, отраслями и размерами компаний. Отдельно включил бы ИП, одноимённые организации, группы, франшизы и ликвидированные юрлица. Нужны и случаи, где сайт не удалось подтвердить. Их нельзя подписывать как «сайта точно нет»: поиск этого не доказывает.

Правильный ответ устанавливается по первичным страницам и имеет дату. Спорные случаи проверяет второй человек. Компании одной группы не стоит случайно распределять между наборами для разработки и итоговой проверки: сайты у них могут совпадать. Кроме отдельного проверочного набора полезен повторный замер спустя некоторое время.

Ошибки поиска и ошибки решения нужно считать раздельно. Если нужный сайт вообще не попал в кандидаты, новый промпт проблему не исправит. На одинаковых данных я бы сравнил первый результат поиска, проверку точного ИНН и проверку с LLM. Так станет видно, где модель помогает и оправдывает ли она свои расходы.

На какие показатели смотреть

Точность показывает долю правильных связей среди всех выданных. Полнота показывает, сколько сайтов найдено среди организаций, для которых сайт подтверждён в эталоне. Покрытие показывает долю ИНН с доменом во всём выбранном сегменте. Эти числа нужны вместе: можно добиться высокой точности, почти всегда возвращая null.

Также нужно считать технические сбои, ложные ответы в случаях без подтверждённого сайта, устаревшие связи и время обнаружения изменений. Для планирования расходов нужны стоимость одного поиска и ручной проверки, медиана и p95 времени обработки. Результаты стоит разбивать по сегментам. Для маленькой выборки важны число наблюдений и интервал неопределённости, а не только процент успеха.

Порог выдачи я бы выбирал по размеченным данным и допустимой цене ошибки. Для этого сервиса ложная связь выглядит хуже пропущенного сайта, поэтому начал бы с высокой точности. Например, 99% можно обсуждать как цель продукта, но прототип такой точности не доказывает.

Как обновлять справочник

Частота проверки зависит от востребованности записи, возраста подтверждения и прошлых ошибок. Для начала можно проверять популярные записи раз в месяц, остальные раз в квартал, затем менять интервалы по статистике. Смена названия, статуса, контактов или реорганизация должна запускать проверку раньше срока. Очередь ограничивается дневным бюджетом.

Сначала достаточно проверить DNS, HTTP и перенаправления. Хеш страницы или HTTP-валидаторы помогут не перечитывать неизменившийся документ. Но работающий сайт мог сменить владельца, поэтому реквизиты всё равно нужно периодически проверять. Парковка домена, исчезновение реквизитов и другой ИНН требуют нового разбора связи.

Один таймаут не должен удалять ранее подтверждённый сайт. Нужны несколько повторов с увеличением интервала. При подтверждённом противоречии домен снимается с выдачи до проверки. Неудачный поиск тоже нельзя кешировать навсегда: его стоит повторить через месяц, а затем делать это реже. Сообщение пользователя об ошибке повышает приоритет, но не заменяет проверку.

Изменения я бы публиковал небольшими версиями с возможностью отката. Перед публикацией проверял бы постоянную контрольную выборку, резкий рост отказов и массовую смену доменов. Новую модель или поисковый сервис сначала сравнивал бы на сохранённых страницах, затем на свежих результатах поиска.

Что остаётся сложным

Часть сайтов не индексируется, не публикует реквизиты или хранит их в сканах. Некоторые страницы закрыты либо требуют исполнения JavaScript. Чужие документы могут быть скопированы, а настоящие реквизиты могут устареть. LLM тоже может неверно понять роль компании при корректной цитате. Поэтому полностью автоматическая проверка не снимает потребность в разборе спорных случаев.

До запуска нужно согласовать определение основного сайта, работу с группами и брендами, допустимую долю ошибок, сроки перепроверки и правила для ликвидированных организаций. Отдельно нужно проверить условия использования источников и хранения материалов. Обход должен учитывать robots.txt и нагрузку на сайты; из данных ИП стоит сохранять только необходимое для задачи.

Бесплатный поиск удобен для прототипа, но не даёт гарантий доступности. Собственный SearXNG тоже зависит от внешних движков. Для массового сбора придётся оценить расходы на инфраструктуру, поддержку поиска и ручные проверки, а не только на токены модели.

Задание 2. Поиск сайта по ИНН

Код: GitHub. Профиль: Ev0lv3nta.

Что делает программа

Программа принимает {"inn":"7721581040"} и возвращает {"domain":"dadata.ru"}. Если подтвердить сайт не удалось, возвращает {"domain":null}. ИНН можно передать через --inn или JSON в stdin. В stdout попадает только ответ, пояснения и ошибки идут в stderr.

Формат ИНН и контрольная сумма проверяются до обращения к сети. Поддерживаются ИНН юридических лиц и ИП, хотя отдельной проверки качества на ИП пока нет. Неверный вход завершает программу с кодом 2, технический сбой с кодом 3, обычный ответ, в том числе обоснованный null, с кодом 0.

Чем ищет и читает

Поиск идёт через CRW REST API и собственный SearXNG. Для чтения страниц используются HTTPX, BeautifulSoup и pypdf. Если этого недостаточно, программа обращается к CRW с Lightpanda и Chromium, запущенным через Playwright. Браузер нужен для страниц, содержимое которых появляется после исполнения JavaScript.

При чтении сохраняются футер, ссылки и публичные данные из JSON-LD и JSON состояния страницы. Это оказалось важно на практике: реквизиты могут находиться за пределами основного текста. Название и регион программа запрашивает в публичном сервисе ЕГРЮЛ/ЕГРИП ФНС. Если он недоступен, поиск продолжается по ИНН. Конфигурация и запуск стека есть в репозитории; доступ к серверу автора не нужен.

В итоговых прогонах использовался бесплатный поиск. Анонимная квота Exa закончилась, другие движки ограничивали запросы. Обновление парсера Yahoo в SearXNG помогло восстановить поиск по названию. Поддержка Tavily и Brave оставлена как дополнительный вариант, но выключена и проверена только на подставных ответах API. Версии поискового стека зафиксированы в документации.

Для анализа используется openai/gpt-6-luna через OpenRouter с reasoning high. Модель выбирает, что искать и читать дальше, и объясняет связь сайта с организацией. Ответ ограничен JSON Schema, затем проверяется Pydantic и обычным Python. Для этого достаточно небольшого цикла без отдельного агентного фреймворка.

LLM платная. Во время проверки миллион входных токенов стоил $0.10, выходных $0.50. Перед запросом программа проверяет тариф и резервирует верхнюю оценку расходов, после ответа записывает фактическую стоимость. По умолчанию бюджет составляет $0.25. Журнал защищён блокировкой от одновременных запусков. Платный поиск и автоматическая замена модели выключены.

Как принимается решение

Сначала программа ищет точный ИНН в ФНС. Первый поисковый запрос состоит из юридического названия, региона и слов «официальный сайт». Если название не получено, используется ИНН в кавычках. Последующие запросы выбирает модель с учётом уже прочитанного.

Из выдачи собираются кандидаты и ссылки. Домены приводятся к общему виду через Public Suffix List с учётом кириллицы и частных зон. Каталоги помогают найти организацию и её сайт, но сами не становятся ответом. Модель выбирает страницы по подписям ссылок: контакты, оферты, реквизиты или документы.

Дальше LLM определяет, кому относится найденный ИНН. Например, реквизиты банка получателя или издателя отдельной книги не подтверждают принадлежность всего сайта. Текст страницы передаётся как данные; инструкции внутри него не должны управлять работой агента.

Для подтверждения модель указывает ID прочитанного источника. Программа сама берёт из него дословный фрагмент с ИНН и проверяет границы числа и домен. Поискового сниппета недостаточно. Если модель сослалась на неподходящий источник или исказила цитату для сравнения сайтов, ей даётся одна попытка исправить ответ. Если связь остаётся неясной, результатом будет null.

На каждом шаге модель может продолжить поиск, запросить до трёх страниц или закончить работу. Она видит историю, ошибки и оставшийся бюджет. Читать разрешено только уже найденные ссылки. Домен выдаётся после действия finish и проверки подтверждения. В выборе сайта нет регулярных выражений, подстановок для известных ИНН и заранее заданных адресов юридических страниц.

Предварительно выбранный сайт проходит дополнительную проверку: действительно ли он основной? Это нужно даже при одном найденном кандидате, который может оказаться отдельным проектом компании. Когда сайтов несколько, для выбора нужны поясняющие цитаты с обоих. При равноправных брендах программа возвращает null. Допустим и другой действующий адрес того же бренда, если его принадлежность подтверждена.

Ограничения одного запуска

На поиск отведено пять минут, до девяти шагов модели, четырёх поисковых запросов, шести активных кандидатов и двенадцати URL. До трёх страниц читаются одновременно. Размер загрузки, число перенаправлений, страницы PDF и объём текста для LLM тоже ограничены.

При HTTP-переходах проверяются адреса частных и служебных сетей. Запрет robots.txt не обходится через удалённый браузер. Для публичного многопользовательского сервиса дополнительно потребуется изолировать сеть браузеров. Поиск и страницы кешируются на сутки; --no-cache отключает кеш. Параметр --trace сохраняет ход работы, источники, решения, время и расходы. В репозитории опубликованы краткие результаты и принятые фрагменты, полные журналы остаются локально.

Как запустить

Нужны Python 3.11+, uv, ключ OpenRouter и CRW. Установка поискового стека описана в stack/README.md. Зависимости клиента устанавливаются командой uv sync --frozen. После настройки ключа пример запуска: uv run inn-site --inn 7721581040. Версии Python-пакетов закреплены в uv.lock, Playwright в package-lock.json.

Для банковских сайтов команда uv run python stack/certificates.py собирает отдельный набор сертификатов с корнями Госуслуг. Проверка TLS остаётся включённой, системное хранилище не меняется.

Что проверено

90 тестов без сетевых запросов проходят командой uv run pytest. Проверка uv run ruff check . также проходит. Скрипты evaluate.py и evaluate_llm.py запускают проверки с настоящими API и расходуют бюджет. Ожидаемые ответы и контрольные URL из tests/cases.json алгоритму не передаются.

В последних результатах для каждого ИНН подтверждено 16 из 16 сайтов, ложных доменов: 0. В случае равноправных брендов получен null, неверный ИНН отклонён до обращения к сети. Это итог нескольких прогонов. В полном прогоне правильными были 14 из 18 ответов; после исправлений четыре проблемных случая проверены заново, все четыре прошли. Остальные 13 сайтов дополнительно проверены текущей моделью на сохранённых страницах, без нового поиска. Полного повторного прогона финальной версии по всем 18 входам не было. Неудачные результаты также сохранены.

Отдельно модель проверена на 17 подготовленных фрагментах с неоднозначными упоминаниями ИНН. Правильных ответов: 17, ложных доменов: 0. Простая проверка наличия ИНН на тех же текстах дала 4 правильных ответа и 13 ложных доменов. На этих примерах чтение контекста помогает отличить владельца сайта от стороннего упоминания. Тексты и ответы есть в репозитории.

В проверке нескольких брендов ожидаемый ответ пришлось изменить после чтения первичных страниц: выбор одного домена был необоснованным. Исходный неудачный результат сохранён. История прогонов находится в reports/validation.md, фрагменты, на которых основаны ответы, в reports/decisions.json.

Что ещё нужно проверить

Примеры подбирались во время разработки, поэтому этот результат нельзя переносить на весь ЕГРЮЛ. Следующий шаг: собрать независимую выборку новых организаций, отдельно проверить ИП и группы компаний. Ошибки инструментов при этом нужно считать отдельно от обоснованных отказов. Проверка неверного ИНН не заменяет случай организации без сайта.

Требование точного ИНН снижает полноту: сайт может существовать без опубликованных реквизитов. Поисковый индекс бывает неполным, страницы недоступными, а модель может ошибиться в роли организации. Распознавание сканов, массовый сбор и обновление справочника в прототип не входят; их место описано в первой части.

При разработке кода, тестов и этого документа использован Codex. Решения проверялись на реальных поисковых запросах и отдельно на сохранённых текстах.

Документация: CRW, SearXNG, Lightpanda, Playwright, ФНС. Для примера DaData использована оферта.